

## ANALISIS DE FACTORES

Idea: Modelar la variabilidad (y dependencias entre sus componentes) de  $\mathbf{X}$  en términos de un número (usualmente más pequeño que  $p$ )<sup>(a)</sup> de variables no observadas (variables latentes) llamadas "factores".

ejemplo: Supóngase que  $\mathbf{X}$  reporta los consumos de  $p$  diferentes bienes en un estudio sobre gastos en los hogares durante cierto mes. Estos gastos podrían ser: agua, luz, internet, teléfono, gas. La forma en que las componentes de  $\mathbf{X}$  varían (así como la forma en que  $X_i$  covaría con  $X_j$ ;  $i, j = 1, 2, \dots, p$ ,  $i \neq j$ ), podría quedar

(a)  $\mathbf{X}$  vector aleatorio de dimensión  $p$   $\mathbf{X} = \begin{pmatrix} X_1 \\ \vdots \\ X_p \end{pmatrix}$ .

Se pretende que el número de factores sea más pequeño que  $p$ , es decir "reducir la dimensión".



explicada por dos o tres factores relacionados con la conducta social de los habitantes.

Ejemplos de estos factores serían: búsqueda de comodidad, deseo de alcanzar cierta clase social, intención de cubrir necesidades básicas.

En la práctica, estos factores no observados resultan de mayor interés para quienes estudian estos fenómenos que las mismas observaciones  $x_{G1}, \dots, x_{Gn}$ . En general estos factores se interpretan como características comunes de  $x_{G1}, \dots, x_{Gn}$ , las cuales no son observadas.

Una forma de plantear esta situación en un modelo sería si para cada  $x_{Gj}$  tenemos

$$(I) \dots X_j = \sum_{z=1}^K a_{jz} f_z + \mu_j \quad ; \quad j=1, 2, \dots, P;$$

$f_z \quad ; \quad z=1, 2, \dots, K$ , son los factores, se espera que  $K$  sea más pequeño (significativamente) que  $P$



Por ejemplo, en estudios psicológicos,  $\mathbf{X}$  podría representar a  $p$  resultados correspondientes a una prueba para medir "inteligencia". Un factor común a las observaciones  $x_{G1}, \dots, x_{Gn}$  es un nivel de "inteligencia" general, que se asume para los miembros de la población.

Para un vector aleatorio  $\mathbf{X}$  de dimensión  $p$ , con media  $\mu$  y matriz de covarianzas  $\Sigma$ , un modelo similar a (I) se puede escribir en notación matricial

$$(II) \quad \mathbf{X} = \mathbf{Q}\mathbf{F} + \mu,$$

donde  $\mathbf{F}$  es una matriz (vector de dimensión  $k \times 1$ ),  $\mathbf{Q}$  es una matriz de dimensiones  $p \times k$  cuyos renglones son los pesos (en la ecuación I) asociados a los componentes de  $\mathbf{X}$ . Para (II), es usual asumir que:  $E(\mathbf{F}) = \mathbf{0}$  y  $\text{VAR}(\mathbf{F}) = \mathbf{I}_k$ , recordemos que los factores son variables aleatorias no observadas (latentes).



4

A continuación veremos que si se asume que los últimos  $p-k$  valores propios de  $\Sigma$  valen 0, entonces la ecuación (II) nos sirve para expresar un modelo de factores.

Sea  $\Sigma = \Gamma \Lambda \Gamma'$  la descomposición de Jordan para  $\Sigma$  y supongamos que  $\lambda_{k+1}, \dots, \lambda_p$  valen 0. En tal caso  $\Sigma$  es singular, pero podemos escribir

$$\begin{aligned} \Sigma &= (\Gamma_1 \Gamma_2) \begin{pmatrix} \Lambda_1 & 0 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} \Gamma_1' \\ \Gamma_2' \end{pmatrix} & \begin{array}{l} \Gamma_1 \quad p \times k \\ \Gamma_2 \quad p \times (p-k) \end{array} \\ &= \sum_{i=1}^k \lambda_i \mathcal{Y}_i \mathcal{Y}_i' & \Lambda_1 = \text{DIAG}(\lambda_1, \dots, \lambda_k) \end{aligned}$$

$\mathcal{Y}_i$  columna  $i$  de  $\Gamma_1$ ;  $i=1, 2, \dots, k$ .

Recordemos ahora que las componentes principales para  $\Sigma$  se definen como  $\mathcal{Y} = \Gamma' (X - \mu)$ .

Podemos escribir esta relación como

$$\begin{aligned} \Gamma \mathcal{Y} &= X - \mu \quad \text{es decir} \quad X - \mu = \Gamma \mathcal{Y} \\ &= \Gamma_1 \mathcal{Y}_1 + \Gamma_2 \mathcal{Y}_2 \end{aligned}$$

donde

$$Y = \begin{pmatrix} Y_1 \\ Y_2 \end{pmatrix} = \begin{pmatrix} \Gamma_1' \\ \Gamma_2' \end{pmatrix} (X - \mu)$$

es un vector aleatorio con momentos

$$E(Y) = \Gamma' E(X - \mu) = 0$$

$$\text{VAR}(Y) = \text{VAR}(\Gamma' (X - \mu))$$

$$= \Gamma' \text{VAR}(X - \mu) \Gamma = \Gamma' \Sigma \Gamma$$

$$= \Lambda = \begin{pmatrix} \Lambda & 0 \\ 0 & 0 \end{pmatrix} \dots \dots \dots \text{III}$$

Notemos que el vector  $Y_2$  tiene una distribución singular con media 0 y matriz de covarianzas 0, luego

$$X - \mu = \Gamma_1' Y_1$$

$$X = \Gamma_1 \Lambda_1^{1/2} \Lambda_1^{-1/2} Y_1 + \mu$$

$$= QF + \mu,$$

$$\text{con } Q = \Gamma_1 \Lambda_1^{1/2} \text{ y } F = \Lambda_1^{-1/2} Y_1.$$

$$\begin{matrix} (p \times k) & (k \times k) \end{matrix}$$

$$\begin{matrix} (k \times k) & (k \times 1) \end{matrix}$$



notemos que

$$\begin{aligned}\Sigma &= E((X-M)(X-M)') = E(QF)(QF)' \\ &= Q E(F'F) Q' = Q E(\Lambda_1^{-1/2} Y_1 (Y_1' \Lambda_1^{-1/2})) \\ &= Q E(\Lambda_1^{-1/2} Y_1 Y_1' \Lambda_1^{-1/2}) Q' \\ &= Q \Lambda_1^{-1/2} E(Y_1 Y_1') \Lambda_1^{-1/2} Q'\end{aligned}$$

ecuación III pág 5  $\longrightarrow$

$$\begin{aligned}&= Q \Lambda_1^{-1/2} \Lambda_1 \Lambda_1^{-1/2} Q' = Q Q' \\ &= \sum_{j=1}^k \lambda_j x_j x_j'\end{aligned}$$

Entonces bajo el supuesto  $\lambda_{k+1} = \lambda_{k+2} = \dots = \lambda_p$ ,  $X$  se puede expresar como una combinación lineal de  $k$  factores ( $k < p$ ) que son no correlacionados (los componentes de  $\Lambda_1^{-1/2} Y_1$ ).

Problema: En la práctica  $\hat{\Sigma}$  no resulta singular, casi siempre.