

Resultado 1 : Si  $x_{G1}, \dots, x_{Gn} \stackrel{i.i.d.}{\sim} N_p(\mu, \Sigma)$

entonces los estimadores de máxima verosimilitud para  $\mu$  y  $\Sigma$  son

$$\hat{\mu} = \bar{x}_{G(n)} \quad \text{y} \quad \hat{\Sigma} = \frac{1}{n} \sum_{j=1}^n (x_{Gj} - \bar{x}_{G(n)})(x_{Gj} - \bar{x}_{G(n)})'$$

Dem ver las notas MLE-MULTIVAR-NORMAL

Resultado 2 : Si  $x_{G1}, \dots, x_{Gn} \stackrel{i.i.d.}{\sim} N_p(\mu, \Sigma)$

entonces  $n\hat{\Sigma} \sim \text{Wishart}_p(\Sigma, n-1)$

Este Teorema se revisó en la página 55 de las notas para componentes principales

Resultado 3 : Si  $x_{G1}, \dots, x_{Gn} \stackrel{i.i.d.}{\sim} N_p(\mu, \Sigma)$

entonces  $\hat{\mu} = \bar{x}_{G(n)}$  y  $n\hat{\Sigma}$  son independientes

Dem Véase Press, S. J., (2005), "Applied Multivariate Analysis, Using Bayesian and Frequentist Methods of Inference", 2<sup>nd</sup> Edition, Dover, Teorema (7.1.2), pag 181, sección 7.1.

Resultado 4 : Si  $x_1, \dots, x_n \stackrel{i.i.d.}{\sim} N_p(\mu, \Sigma)$

entonces  $(\hat{\mu}, n\hat{\Sigma})$  es suficiente para  $\Theta = (\mu, \Sigma)$ .

Dam véase Press, S.J. (2005) ...,

Teorema (7.1.1), página 181, sección 7.1

Estimación de máxima verosimilitud para  $\Theta$  y  $\Psi$  (Lawley y Maxwell, 1963. Anderson y Rubin, 1956), ..

Argumento (caso variables discretas) :

Sean  $f(x_1, \dots, x_n, \theta)$  la densidad de  $X_1, \dots, X_n$  y  $f(x_1, \dots, x_n, t, \theta)$  la densidad conjunta de  $X_1, \dots, X_n, T(x_1, \dots, x_n)$ , donde  $T$  es una estadística suficiente para  $\theta$ .

$$f(x_1, \dots, x_n, t, \theta) = \mathbb{P}(X_1=x_1, \dots, X_n=x_n, T=t; \theta)$$

$$= \mathbb{P}(X_1=x_1; \dots; X_n=x_n; \theta) = f(x_1, \dots, x_n, \theta)$$

↑

si  $t$  es tal que  $T(x_1, \dots, x_n) = t$



$$f(x_1, \dots, x_n, \theta) = f(x_1, \dots, x_n, t, \theta) =$$

$$f(x_1, \dots, x_n | t, \theta) f(t, \theta)$$

$$\stackrel{\uparrow}{=} f(x_1, \dots, x_n | t) f(t, \theta)$$

$t$  es  
suficiente

Como el primer factor no depende de  $\theta$ , para maximizar  $f(x_1, \dots, x_n, \theta)$  c.r. a  $\theta$  debemos maximizar  $f(t, \theta)$  c.r. a  $\theta$ .

---

Para poder aplicar este argumento al caso<sup>(1)</sup>, recordemos que  $\overline{x}_{G(n)} \sim N_p(\mu, \frac{1}{n} \Sigma)$ , entonces por el resultado 3

$$f_{\hat{\mu}, n \hat{\Sigma}}(t_1, t_2) = f_{\hat{\mu}}(t_1) f_{n \hat{\Sigma}}(t_2)$$

$$\stackrel{(2)}{=} N_p(t_1; \mu, \frac{1}{n} \Sigma) \cdot \text{Wishart}_p(t_2; \Sigma, n-1)$$

que es la densidad conjunta de  $T(x_{G1}, \dots, x_{Gn}) = (\hat{\mu}, n \hat{\Sigma})$ <sup>(3)</sup>

(1)  $x_{G1}, \dots, x_{Gn} \stackrel{iid}{\sim} N_p(\mu, \Sigma)$

(2) Usando: Resultado 2.

(3)  $T(x_{G1}, \dots, x_{Gn})$  suficiente

Resultado 4:

$$\tilde{L}_T(t, \mu, \Sigma) = f_{\hat{\mu}, n\hat{\Sigma}}(t_1, t_2)$$

De acuerdo al argumento dado arriba, hay que maximizar a  $\tilde{L}_T(t, \theta) = \tilde{L}_T(t, \mu, \Sigma)$

como función de  $\mu, \Sigma$ , pero como lo que nos interesa son los parámetros  $Q$  y  $\Psi$ , entonces podemos substituir

$\Sigma = QQ' + \Psi$  en  $\tilde{L}_T(t, \mu, \Sigma)$  y maximizar esta última c.r.a  $Q$  y  $\Psi$ . Tomando logaritmos

$$l(\mu, Q, \Psi, \underline{x}) = \log \tilde{L}_T(t, \mu, QQ' + \Psi)$$

$$= \log \left\{ N_p(t_1, \mu, \frac{1}{n}(QQ' + \Psi)) \times \text{Wishert}_p(t_2; QQ' + \Psi, n-1) \right\}$$

$$= c + \left( \frac{n-p-2}{2} \right) \log |A| - \frac{n}{2} \log |QQ' + \Psi|$$

$$- \frac{1}{2} \text{tr}[(QQ' + \Psi)^{-1} A] - \frac{n}{2} (\bar{x}_{(n)} - \mu)' (QQ' + \Psi)^{-1} (\bar{x}_{(n)} - \mu),$$

$A=n \sum$

donde  $c$  es una constante que no depende de  $Q, \Psi$  y  $\underline{x}$ .

Notemos que al hacer  $\mu = \hat{\mu}$  el último término se cancela, después de esto, si

se deriva con respecto a  $Q$  y  $\Psi_{11}, \Psi_{22}, \dots, \Psi_{pp}$  y se igualan estas derivadas a 0, se obtiene



un sistema de ecuaciones

$$\text{Diag}(\hat{\Psi} + \hat{Q}\hat{Q}') = \text{Diag}(\hat{\Sigma}),$$

$$\hat{\Sigma} \hat{\Psi}^{-1} \hat{Q} = \hat{Q}(\mathbb{I} + \hat{Q}' \hat{\Psi}^{-1} \hat{Q}),$$

que deben satisfacer los estimadores de máxima verosimilitud  $\hat{Q}$  y  $\hat{\Psi}$ .

Modelo para datos estandarizados

$$X = QF + U + \underline{\mu}$$

donde denotando  $\mathcal{D} = \text{DIAG}(\text{VAR}(X_1), \dots, \text{VAR}(X_p))$   
tenemos que

$$\mathcal{D}^{-1/2}(X - \underline{\mu}) = (\mathcal{D}^{-1/2}Q)F + \mathcal{D}^{-1/2}U \dots (I)$$

$$\mathcal{D}^{-1/2}Q = Q_Y; \quad Y = \mathcal{D}^{-1/2}(X - \underline{\mu}); \quad \mathcal{D}^{-1/2}U = U_Y$$

$$Y = Q_Y F + U_Y, \dots (II)$$

donde

$$\begin{aligned} \text{VAR}(U_Y) &= \text{COV}(\mathcal{D}^{-1/2}U, \mathcal{D}^{-1/2}U) \\ &= \mathcal{D}^{-1/2} \text{COV}(U, U) \mathcal{D}^{-1/2} \\ &= \mathcal{D}^{-1/2} \Psi \mathcal{D}^{-1/2} \end{aligned}$$

Al calcular  $\text{VAR}(\cdot)$  en ambos lados de (II)  
(usando los supuestos (2) en la página 8 tenemos

matriz de correlaciones de  $X \longrightarrow$

$$\begin{aligned} R &= \text{COV}(\mathcal{D}^{-1/2}QF, \mathcal{D}^{-1/2}QF) + \text{COV}(\mathcal{D}^{-1/2}U, \mathcal{D}^{-1/2}U) \\ &= \mathcal{D}^{-1/2}Q \text{COV}(F, F) Q' \mathcal{D}^{-1/2} + \mathcal{D}^{-1/2} \Psi \mathcal{D}^{-1/2} \\ &= Q_Y Q_Y' + \Psi_Y \end{aligned}$$

Para estimar  $Q_Y$  y  $\Psi_Y$  en (II)

usamos los MLE's  $\hat{Q}$  y  $\hat{\Psi}$  obtenidos en las páginas 15-16, de donde

$$\hat{Q}_Y = \hat{\Sigma}^{-1/2} \hat{Q}$$

$$\hat{\Psi}_Y = \hat{\Sigma}^{-1/2} \hat{\Psi} \hat{\Sigma}^{-1/2}$$

$$\hat{\Sigma} = \text{DIAG}(\widehat{\text{VAR}}(X_1), \dots, \widehat{\text{VAR}}(X_p))$$