

$$\hat{Q}\hat{Q}^T + \hat{\Psi} = \begin{pmatrix} 1.0 & 0.01 & 0.97 & 0.44 & 0.0 \\ 0.01 & 1.0 & 0.11 & 0.79 & 0.91 \\ 0.97 & 0.11 & 1.0 & 0.53 & 0.11 \\ 0.44 & 0.79 & 0.53 & 1.0 & 0.81 \\ 0.0 & 0.91 & 0.11 & 0.81 & 1.0 \end{pmatrix}$$

y esta última matriz está muy cercana a la matriz de correlación muestral  $\hat{R}$ . Las comunidades (0.98, 0.88, 0.98, 0.89, 0.93) nos indican que los dos factores explican en forma adecuada la varianza muestral de cada una de las variables  $X_1, X_2, \dots, X_5$ . Se puede aprovechar la no unicidad de los pesos de los factores, para encontrar una rotación que permita una mejor interpretación.

### METODO VARIMAX PARA ENCONTRAR ROTACION

(Kaiser, 1985)

Supóngase que la matriz  $G = G(\theta)$  representa una rotación, en el sentido de las manecillas del reloj, de los ejes de coordenadas, donde  $\theta$  es el ángulo que define la rotación.

Los pesos transformados (rotados) con  $G(\theta)$

estén dados por  $\hat{Q}_\theta^* = \hat{Q} \cdot D(\theta)$ . Sea  $\hat{q}_{ij}^*$  el elemento  $i$  en la columna  $j$  de  $\hat{Q}_\theta^*$  y sea  $\tilde{q}_{ij} = (\hat{q}_{ij}^*)^2$ , la varianza de los cuadrados de los pesos en la columna 1 de  $\hat{Q}_\theta^*$ ,  $1=1,2,\dots,k$  es

$$\widehat{\text{VAR}}(\tilde{q}_{.1}) = \frac{1}{P} \sum_{j=1}^P \tilde{q}_{j1}^2 - (\bar{\tilde{q}}_{.1})^2, \quad (1)$$

donde  $\bar{\tilde{q}}_{.1} = \frac{1}{P} \sum_{j=1}^P \tilde{q}_{j1}$ .

Al sumar estas varianzas para  $1=1,2,\dots,k$ , tenemos

$$V_\theta \equiv \sum_{1=1}^k \widehat{\text{VAR}}(\tilde{q}_{.1}) = \frac{1}{P} \sum_{1=1}^k \left\{ \sum_{j=1}^P (\hat{q}_{j1}^*)^4 - \left( \frac{1}{P} \sum_{j=1}^P (\hat{q}_{j1}^*)^2 \right)^2 \right\}.$$

Kaiser (1985), propuso seleccionar  $\theta$ , donde  $V_\theta$  alcanza un máximo.

Para el conjunto de datos correspondiente a las preferencias de los consumidores, los pesos de los factores 1 y 2 tienen magnitudes que

$$(1) \quad y_1, \dots, y_n \text{ obs.} \quad \widehat{\text{VAR}}(Y) = \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2 = \frac{1}{n} \sum_{i=1}^n y_i^2 - \bar{y}^2$$



no facilitan una interpretación de estos factores.  
Al aplicar una rotación determinada por el método varimax obtenemos

	$\tilde{q}_1$	$\tilde{q}_2$	
1 Gusto	0.02	0.99	
2 Relación Calidad-Precio	0.94	-0.01	
3 Sabor	0.13	0.98	
4 Posibilidad uso botena	0.84	0.43	
5 Grado de energía	0.97	-0.02	

Podemos interpretar ahora, que el primer factor está determinado por las variables 2, 4 y 5. (este factor parece ser más bien nutricional).

Por otra parte, el segundo factor está determinado por las variables 1 y 3 (este factor parece ser más bien relacionado al gusto de los consumidores)

### Factor Scores (estimación de los Factores)

Los valores estimados de los factores suelen llamarse

"factor scores" y pueden ser de utilidad para análisis y diagnósticos en los modelos. Los scores son estimaciones de los factores  $F_1, \dots, F_k$ , para cada individuo en una muestra  $x_{g1}, \dots, x_{gn}$ .

Supuesto: La distribución conjunta de  $(X - \mu)$  y  $F$  es normal multivariada.

Del modelo IV, página 7, la matriz de varianzas covarianzas conjunta de  $(X - \mu)$  y  $F$  es

$$(10) \dots \text{VAR} \begin{pmatrix} X - \mu \\ F \end{pmatrix} = \begin{pmatrix} QQ' + \Psi & Q \\ Q' & I_k \end{pmatrix} \quad \leftarrow \text{dims } (p+k) \times (p+k)$$

la submatriz  $QQ' + \Psi$  de dimensiones  $p \times p$  equivale a la varianza de  $X - \mu$ , es decir  $\Sigma$ . Del supuesto de normalidad conjunta de  $(X - \mu)$  y  $F$ , se tienen resultados sobre la distribución de  $F$  condicional a  $X$  (véase, por ej. Wikipedia, página sobre el tema "Multivariate Normal Distribution", o bien cualquier texto sobre



Análisis Multivariado), esta distribución condicional  $(f_{F|X})$  es normal multivariada con vector de medias dado por

$$E(F|X=x) = Q' \Sigma^{-1} (X - \mu),$$

así como con matriz de varianzas-covarianzas

$$\text{VAR}(F|X=x) = I_K - Q' \Sigma^{-1} Q.$$

Para construir el estimador  $\hat{f}_i$  de  $F_i$ , reemplazamos  $Q$ ,  $\Sigma$  y  $\mu$  por sus correspondientes estimadores

$$\hat{f}_i = \hat{Q}' \hat{\Sigma}^{-1} (x_{4i} - \bar{x}_n); \quad i=1,2,\dots,n.$$

La misma idea se puede seguir si se quiere usar  $\hat{R}$  en lugar de  $\hat{\Sigma}$ , en tal caso  $\Sigma \equiv \mathcal{D}^{-1/2} (X - \mu)$  con  $\mathcal{D} = \text{diag}(\text{VAR}(x_1), \dots, \text{VAR}(x_p))$  y en lugar de (2a) tenemos

$$(2b) \quad \dots \quad \text{VAR} \begin{pmatrix} Z \\ F \end{pmatrix} = \begin{pmatrix} Q_z Q_z' + \Psi_z & Q_z \\ Q_z & I_K \end{pmatrix}$$

Los estimadores  $\hat{f}_i$  en este caso son

$$\hat{f}_i = \hat{Q}' \hat{R}^{-1} z_i,$$

donde  $z_i \equiv \hat{D}^{-1/2} (x_{ki} - \bar{x}_k)$ ,  $\hat{Q}$  es la matriz de pesos obtenida a partir de  $\hat{R}$  y  $\hat{D} = \text{diag}(\hat{\text{var}}(x_1), \dots, \hat{\text{var}}(x_p))$ .

nota: Si se usa una rotación  $G$  para mejorar la interpretación de los factores  $F$ , entonces se debe rotar a los factor scores

$$\hat{f}_i^* = G \hat{f}_i$$