

valor más pequeño del cociente

$$h(x_1, \dots, x_N) = \frac{\sum_{i=1}^N x_i^2}{N \sum_{i=1}^N (x_i - \bar{x})^2}$$

Tarea: demuestre que para un tamaño de muestra fijo  $N$  la función  $h$  se minimiza si  $\bar{x} = 0$ .

La conclusión es que  $\hat{\beta}_0$  y  $\hat{\beta}_1$  son estimadores lineales e insesgados para  $\beta_0$  y  $\beta_1$ , cuyas varianzas dependen de los valores de la variable explicativa  $X$ . El siguiente teorema establece que  $\hat{\beta}_0$  y  $\hat{\beta}_1$  son estimadores; que dentro de la clase o conjunto de los estimadores lineales insesgados para  $\beta_0$  y  $\beta_1$ , tienen la varianza más pequeña.

### TEOREMA (GAUSS-MARKOV)

Sean  $Y_1, \dots, Y_N$  v.d. tales que

(i)  $E(Y_i) = \beta_0 + \beta_1 x_i$ ;  $i=1, 2, \dots, N$ ,

(ii)  $VAR(Y_i) = \sigma^2$ ;  $i=1, 2, \dots, N$ ,

(iii)  $Cov(Y_i, Y_j) = 0 \quad \forall i \neq j \quad (i, j=1, 2, \dots, N)$ ,



donde  $x_1, \dots, x_N$  son constantes conocidas. Entonces los estimadores de mínimos cuadrados  $\hat{\beta}_0$  y  $\hat{\beta}_1$  son los Mejores Estimadores Lineales Insesgados (MELI) de  $\beta_0$  y  $\beta_1$ , en el sentido de varianza mínima.

NOTA: En el idioma Inglés se dice que  $\hat{\beta}_0$  y  $\hat{\beta}_1$  son los BLUE (Best Linear Unbiased Estimators)

NOTA: El teorema no establece que  $\hat{\beta}_0$  y  $\hat{\beta}_1$  son óptimos en general. Lo que establece es que  $\hat{\beta}_0$  y  $\hat{\beta}_1$  son los mejores, dentro de una clase particular de estimadores, la clase o conjunto de los estimadores lineales e insesgados.

Si quisiéramos comparar  $\hat{\beta}_0$  y  $\hat{\beta}_1$  con los estimadores que se obtienen con otros métodos estadísticos, podríamos pensar en estimar  $\beta_0$  y  $\beta_1$  vía momentos o vía Máxima Verosimilitud. El método de momentos no funcionará, toda vez que este supone que las variables aleatorias que se observan son idénticamente distribuidas, que en nuestro caso no se tiene ( $IE(Y_i)$  no es igual a  $IE(Y_j)$ ).



Entonces pensaremos como estimar  $\beta_0$  y  $\beta_1$  vía el método de Máxima Verosimilitud. Lo anterior requiere tener la distribución conjunta para las variables que se observan.

Como la variable aleatoria  $\epsilon$  describe el efecto de todos los factores, distintos de la variable explicativa, que no estén fijos en el estudio, no parecería verosímil que tome valores en un conjunto finito o numerable, así que suena razonable asumir que  $\epsilon$  es una v.d. continua.

Gauss estudió el comportamiento empírico de los errores en la estimación de distancias a objetos en la bóveda celeste, a partir de ese análisis sugirió que la distribución debería ser unimodal y simétrica con media 0. En particular si se piensa en  $\epsilon$  como la suma infinita de efectos que no estén bajo control en el estudio (y que no tienen relación con  $X$ ) podemos conectar esta concepción de  $\epsilon$  con el Teorema Central del Límite, que establece que bajo algunos



condiciones, las sumas de variables aleatorias tienen distribución "cerca" a ser Normal.

### MODELO DE REGRESION LINEAL NORMAL

$$Y = \beta_0 + \beta_1 X + \varepsilon,$$

donde  $\varepsilon$  es una v.a. con distribución  $N(0, \sigma^2)$ .

Los datos son generados con la relación

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i ; i=1, 2, \dots, N,$$

donde  $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_N$  son variables aleatorias idénticamente distribuidas e independientes según el modelo Normal  $(0, \sigma^2)$ .

Esta estructura conduce a la siguiente formulación alternativa del Modelo Lineal Normal, el cual está vinculado con la discusión en las primeras páginas de estas notas

"  $Y_1, Y_2, \dots, Y_N$  son v.a. independientes y tales que  $Y_i | X_i = x_i \sim \text{Normal}(\beta_0 + \beta_1 x_i, \sigma^2)$  "

Bajo esta premisa, la verosimilitud (la función

de densidad conjunta de  $Y_1, \dots, Y_N$  condicional  
a  $X_1=x_1; \dots; X_N=x_N$  es

$$\begin{aligned}
 L(\beta_0, \beta_1, \sigma^2) &= f_{Y_1, \dots, Y_N | X_1, \dots, X_N}(y_1, \dots, y_N | x_1, \dots, x_N, \beta_0, \beta_1, \sigma^2) \\
 &= \prod_{i=1}^N f_{Y_i | X_i}(y_i | x_i, \beta_0, \beta_1, \sigma^2) \\
 &= \prod_{i=1}^N \left\{ (2\pi\sigma^2)^{-1/2} e^{-\frac{1}{2\sigma^2} [y_i - (\beta_0 + \beta_1 x_i)]^2} \right\} \\
 &= (2\pi\sigma^2)^{-n/2} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^N (y_i - \beta_0 - \beta_1 x_i)^2}
 \end{aligned}$$

estamos en  $x_1, \dots, x_N$  en conjunto